Reinforcement Learning Assignment

Ομάδα Συνεργατών: Θοδωρής Γρηγορίου MTN2506, Νίκος Μάριος Σπυρόπουλος MTN 2525, Μιχάλης Μυκωνιάτης MTN2518

GitHub repository:https://github.com/TgDSML/multi-agent-rl-coordination-game

1. Εισαγωγή

Τα παίγνια συντονισμού (coordination games) αποτελούν μια βασική κατηγορία αλληλεπίδρασης στα πολυπρακτορικά συστήματα, όπου οι πράκτορες αποκομίζουν μεγαλύτερη ανταμοιβή όταν επιλέγουν συμβατές ή ακόμα και ίδιες ενέργειες με τους υπόλοιπους. Σε αντίθεση με τα ανταγωνιστικά παίγνια, το βασικό χαρακτηριστικό των coordination games είναι η ύπαρξη πολλαπλών πιθανών ισορροπιών Nash, στις οποίες οι πράκτορες επιτυγχάνουν αμοιβαία βελτιωμένα αποτελέσματα μέσω συντονισμού. Επομένως το ερώτημα είναι ποιά ισορροπία θα επιλεγεί και υπό ποιές συνθήκες.

Τα graphical games επεκτείνουν το παραπάνω πλαίσιο εισάγοντας τοπική δομή αλληλεπίδρασης. Οι πράκτορες δεν αλληλεπιδρούν όλοι μεταξύ τους καθώς οι στρατηγικές αλληλεπιδράσεις περιορίζονται σε ένα γράφο γειτνίασης, όπου οι ακμές καθορίζουν ποιοι πράκτορες επηρεάζουν άμεσα ο ένας τον άλλον.

Στην εργασία αυτή μελετάμε ένα επαναληπτικό coordination game σε αραιό γράφο επτά πρακτόρων (κόμβων) οι οποίοι ανήκουν σε δύο διαφορετικούς τύπους (X και Y). Η δυναμική εξέλιξη του συστήματος πραγματοποιείται μέσω πολυπρακτορικής ενισχυτικής μάθησης και συγκεκριμένα μέσω Q-learning με ε-greedy εξερεύνηση. Εξετάζονται δύο σενάρια: α)περίπτωση χωρίς πληροφορία κατάστασης, όπου οι πράκτορες μαθαίνουν μόνο βάσει της συνολικής ανταμοιβής τους, και β)περίπτωση με πληροφορία γείτονα, όπου η κατάσταση κάθε πράκτορα ορίζεται από τις ενέργειες των γειτόνων του. Στόχος είναι η διερεύνηση της σύγκλισης σε στρατηγικές συντονισμού και η κατανόηση του ρόλου της τοπολογίας και της πληροφορίας στη διαδικασία μάθησης.

2. Formulation

Θεωρούμε ένα επαναληπτικό graphical coordination game που ορίζεται πάνω σε ένα μη κατευθυνόμενο γράφο

$$G = (V, E)$$

Όπου V είναι το σύνολο των πρακτόρων (κόμβων) και E το σύνολο των ακμών που δηλώνουν τις τοπικές αλληλεπιδράσεις. Στην εργασία συγκεκριμένα έχουμε, $|V|$ = 7 και είναι αραιός, δηλαδή κάθε πράκτορας αλληλεπιδρά μόνο με περιορισμένο αριθμό γειτόνων.

Κάθε πράκτορας $i \in V$ επιλέγει σε κάθε χρονική στιγμή μία ενέργεια

$$a_i \in \{1, 2\}.$$

Οι πράκτορες ανήκουν σε δύο διαφορετικούς τύπους Χ και Υ, οι οποίοι διαφέρουν ως προς τις προτιμήσεις τους για τις διαθέσιμες ενέργειες. Η ανταμοιβή κάθε πράκτορα προκύπτει από το άθροισμα των απολαβών που λαμβάνει από τα τοπικά παιχνίδια συντονισμού με τους γείτονές του.

Για κάθε ακμή $(i, j) \in E$, ορίζεται ένα διμερές coordination game. Εάν δύο πράκτορες επιλέξουν την ίδια ενέργεια, λαμβάνουν θετική ανταμοιβή. Οι πράκτορες τύπου Χ ευνοούνται περισσότερο όταν επιλέγεται η ενέργεια 1, ενώ οι πράκτορες τύπου Υ ευνοούνται περισσότερο όταν επιλέγεται η ενέργεια 2. Αν οι πράκτορες επιλέξουν διαφορετικές ενέργειες, η ανταμοιβή είναι χαμηλότερη.

Η συνολική ανταμοιβή ενός πράκτορα i στη χρονική στιγμή t δίνεται από:

$$r_i{}^t = \sum_{j \in N(i)} u_i(a_i{}^t, a_j{}^t),$$

Όπου $N(i)$ είναι το σύνολο των γειτόνων του i , και u_i η τοπική συνάρτηση ανταμοιβής στο διμερές παιχνίδι.

Το παίγνιο επαναλαμβάνεται για Τ επεισόδια και οι πράκτορες μαθαίνουν αυτόνομα μέσω Q-learning με ε-greedy πολιτική εξερεύνησης. Η παράμετρος εξερεύνησης ε ξεκινά από 1
Και μειώνεται σταδιακά κατά 0.01 κάθε Χ επεισόδια, μέχρι να μηδενιστεί στο 80% της συνολικής διάρκειας, ενώ στο τελευταίο 20% εφαρμόζεται καθαρό exploitation.

Έχουμε δύο διαφορετικά σενάρια πληροφόρησης:

1. **Χωρίς πληροφορία κατάστασης (No-information case):**
   Κάθε πράκτορας θεωρεί ότι βρίσκεται σε μία ενιαία κατάσταση. Η μάθηση ισοδυναμεί με πρόβλημα multi-armed bandit, όπου ενημερώνονται οι τιμές $Q(a)$ βάσει της παρατηρούμενης συνολικής ανταμοιβής.

2. **Με πληροφορία γειτονίας (Neighbor-information case):**
   Η κατάσταση κάθε πράκτορα ορίζεται ως:
   $$s_i{}^t = (a_j{}^t : j \in N(i)),$$
   Δηλαδή ως το διάνυσμα των ενεργειών των γειτόνων του. Στην περίπτωση αυτή εφαρμόζεται πλήρες Q-learning:
   $$Q(s, a) \leftarrow Q(s, a) + a[r + \gamma max Q(s', a') - Q(s, a)],$$
   Οπου γ ο συντελεστής προεξόφλησης.

3. Μεθοδολογία

3.1 Περιβάλλον και υπολογισμός ανταμοιβών

Το περιβάλλον υλοποιεί ένα coordination game δύο ενεργειών {1,2} με ασύμμετρες προτιμήσεις Ανά τύπο πράκτορα (X, Y). Για κάθε ακμή (i, j) του γράφου, η τοπική ανταμοιβή του πράκτορα i εξαρτάται από το ζεύγος ενεργειών (a_i, a_j) και τον τύπο του: εάν $a_i = a_j$= 1 ευνοείται περισσότερο ο τύπος X, ενώ αν $a_i = a_j$= 2 ευνοείται περισσότερο ο τύπος Y. Σε περίπτωση ασυμφωνίας έχουμε χαμηλότερη ανταμοιβή.

3.2 Πράκτορες: ε-greedy πολιτική και Q-τιμές

Κάθε πράκτορας υλοποιείται ως Q-agent με πίνακα τιμών Q της μορφής (*state, action*). Η επιλογή ενέργειας γίνεται με ε-greedy πολιτική:

- Με πιθανότητα ε γίνεται εξερεύνηση (τυχαία επιλογή ενέργειας),
- Με πιθανότητα 1-ε γίνεται εκμετάλλευση (επιλογή ενέργειας με τη μέγιστη εκτιμώμενη τιμή Q, με τυχαία επιλογή σε περίπτωση ισοπαλίας)

3.3 Πρόγραμμα εξερεύνησης (step ε-decay)

Σε όλα τα πειράματα χρησιμοποιείται stepwise μείωση του ε: ξεκινά από 1.0 και μειώνεται κατά 0.01 κάθε *decay_every* επεισόδια, μέχρι το 80% της συνολικής διάρκειας. Στο τελευταίο 20% ισχύει ε = 0 (καθαρό exploitation). Στην υλοποίηση επιλέγεται:

$$\text{Decay_every} \simeq \frac{0.8 \cdot T}{100},$$

Ώστε το ε να προσεγγίζει το 0 στο τέλος της φάσης εξερεύνησης.

3.4 Σενάριο A: No-information (single-state / bandit learning)

Στη περίπτωση χωρίς πληροφορία κατάστασης, όλοι οι πράκτορες θεωρούν ότι βρίσκονται σε μία ενιαία κατάσταση s = None (δηλαδή δεν μοντελοποιείται state). Έτσι το πρόβλημα ανάγεται σε bandit-like μάθηση πάνω στις δύο ενέργειες. Η ενημέρωση γίνεται με incremental update:

$$Q(a) \leftarrow Q(a) + a(r - Q(a)) ,$$

Όπου α είναι ο ρυθμός μάθησης. Αυτή η μορφή αντιστοιχεί ακριβώς στη μέθοδο *update_bandit* του πράκτορα.

3.5 Σενάριο B: Neighbor-Information (state-dependent Q-learning)

Στη δεύτερη περίπτωση, κάθε πράκτορας διαθέτει κατάσταση που προκύπτει απο τις ενέργειες των γειτόνων του. Συγκεκριμένα, για κάθε πράκτορα i ορίζεται:

$$s_i = (a_j : j \in N(i)),$$

Ως, στην περίπτωση μας, ζεύγος ενεργειών γειτόνων σε σταθερή σειρά (sorted neighbor order) ώστε η κατάσταση να είναι αναπαραγωγίσιμη.

Η ενημέρωση των Q-τιμών γίνεται με πλήρες Q-learning:

$$Q(s,a) \leftarrow Q(s,a) + a[r + \gamma max Q(s',a') - Q(s,a)],$$

Όπου γ είναι ο συντελεστής προεξόφλησης και s' η επόμενη κατάσταση. Στην υλοποίηση μας, για να οριστεί καθαρά η μετάβαση, το state κάθε πράκτορα στο επεισόδιο t υπολογίζεται από τις ενέργειες των γειτόνων στο προηγούμενο βήμα (*prev_actions*), ενώ το *next_state* προκύπτει από τις τρέχουσες ενέργειες (*actions).*

3.6 Μετρικές και οπτικοποίηση

Για την αξιολόγηση καταγράφονται:
i) Οι Q-τιμές για συγκεκριμένους πράκτορες που ζητούνται (Y1, X1, X3) και
ii) Η μέση συνολική ανταμοιβή ανά τύπο (μέσο reward όλων των X και όλων των Y ανά επεισόδιο)

4. Πειραματικά αποτελέσματα

4.1 Σενάριο χωρίς πληροφορία κατάστασης (No-Information)

Στην περίπτωση χωρίς πληροφορία κατάστασης, όπως ήδη αναφέραμε, κάθε πράκτορας μαθαίνει σε ένα ενιαίο state με bandit-style ενημέρωση. Απο τα διαγράμματα Q-values για τους πράκτορες Y1, X1 και X3 παρατηρείται σαφής σύγκλιση των τιμών μετά από περίπου 3500-4000 επεισόδια, όταν δηλαδή το ε μηδενίζεται και η πολιτική γίνεται καθαρά exploit.

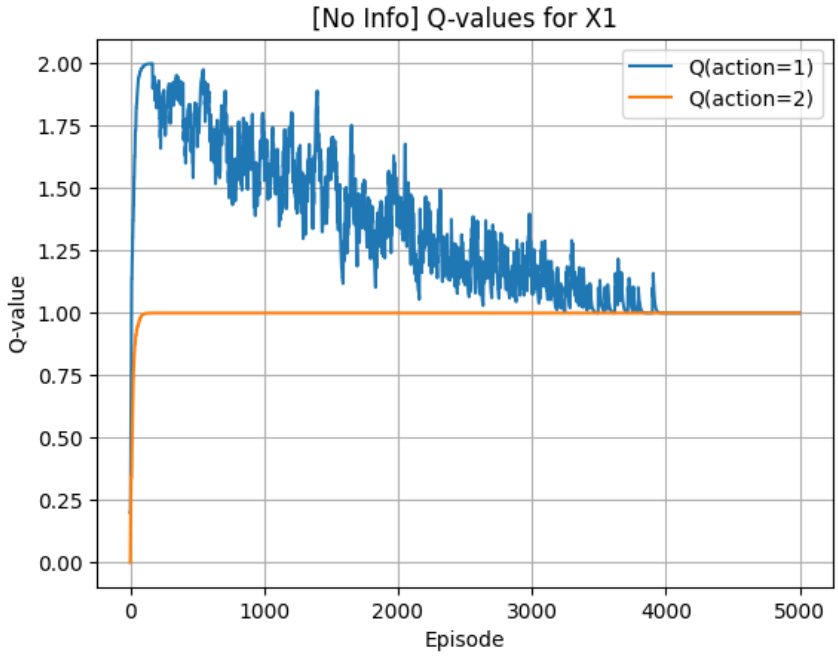

Για τον X1, οι δύο Q-τιμές συγκλίνουν σε παρόμοια επίπεδα, γεγονός που υποδηλώνει ότι ο συγκεκριμένος κόμβος βρίσκεται σε σχεδόν ουδέτερη θέση στο δίκτυο, με περιορισμένη στρατηγική πίεση από τους γείτονές του.

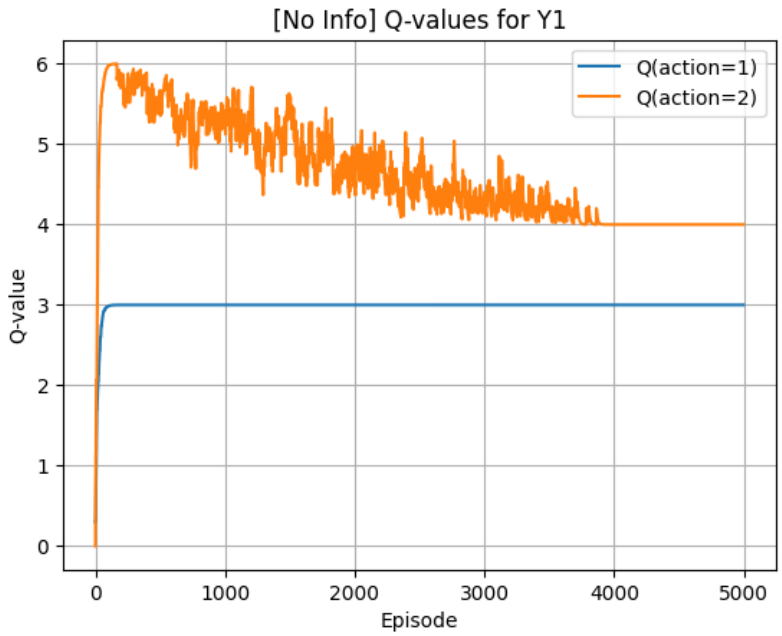

Για τον πράκτορα Y1, η τιμή Q(2) υπερτερεί της Q(1) και σταθεροποιείται περίπου στο 4, ενώ η Q(1) συγκλίνει κοντά στο 3. Αυτό υποδηλώνει ότι η ενέργεια 2 αποτελεί τη βέλτιστη επιλογή για τον συγκεκριμένο πράκτορα στο τελικό convention.

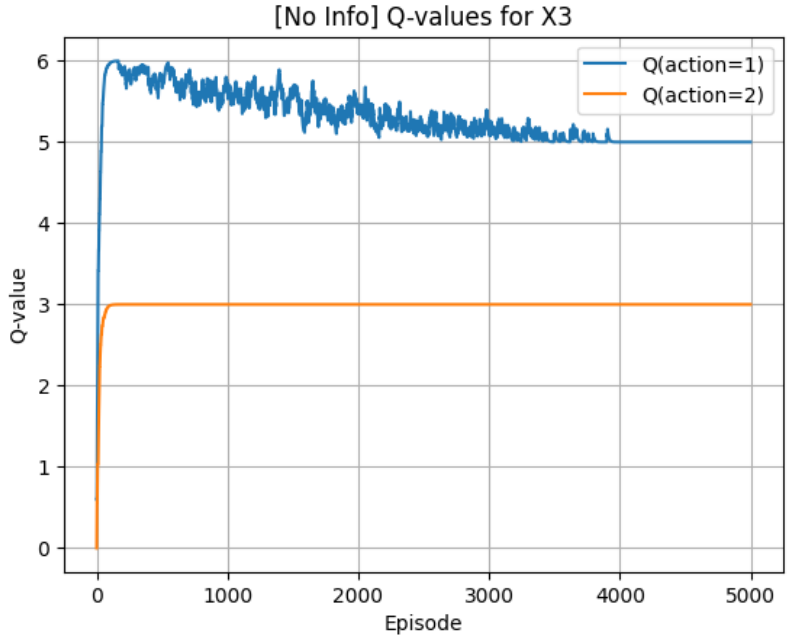

Για τον X3 παρατηρείται σαφής υπεροχή της ενέργειας 1, με Q(1) να συγκλίνει κοντά στο 5 και Q(2) γύρω στο 3, επιβεβαιώνοντας ότι ο X3 συντονίζεται στη δράση που ευνοεί τον τύπο X.

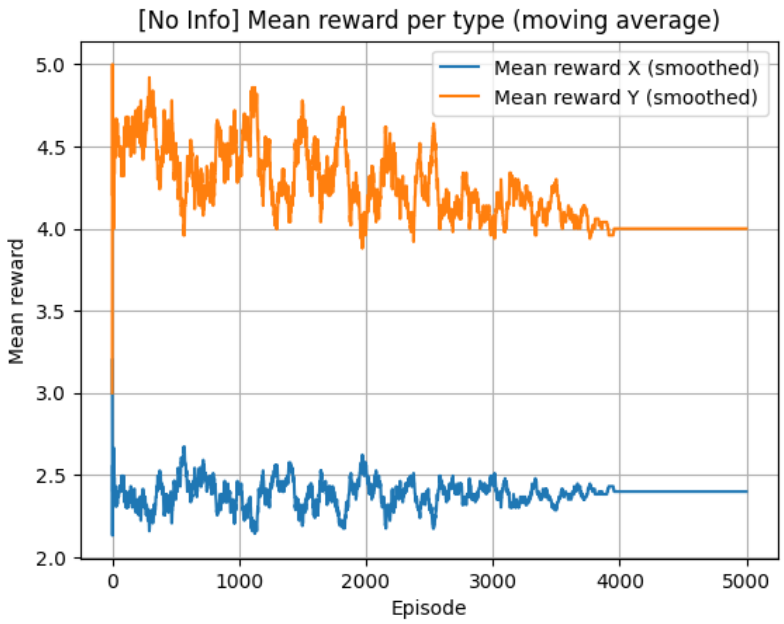

Στο διάγραμμα μέσης ανταμοιβής ανά τύπο (με κινούμενο μέσο όρο 50 επεισοδίων), παρατηρείται σταθεροποίηση μετά το επεισόδιο ~3800. Οι πράκτορες τύπου Y επιτυγχάνουν υψηλότερη μέση ανταμοιβή (≈4.0) σε σχέση με τους τύπου X (≈2.4). Η διαφορά αυτή ερμηνεύεται από τη δομή του γράφου: οι κόμβοι τύπου Y έχουν υψηλότερο βαθμό σύνδεσης και συνεπώς επηρεάζουν περισσότερο το τελικό convention.

4.2 Σενάριο με πληροφορία γείτονα (Neighbor-Information)

Στη δεύτερη περίπτωση, κάθε πράκτορας διαθέτει κατάσταση που αντιστοιχεί στις ενέργειες των γειτόνων του και εφαρμόζεται πλήρες Q-learning με προεξόφληση (γ=0.95). Όπως αναμενόταν θεωρητικά, οι Q-τιμές αποκτούν σημαντικά μεγαλύτερη κλίμακα (έως ~100), καθώς προσεγγίζουν την προεξοφλημένη αναμενόμενη αθροιστική ανταμοιβή:

$$Q \simeq \frac{r}{1-\gamma}$$

Τα διαγράμματα Q-values εμφανίζουν μεγαλύτερη μεταβλητότητα κατά τη φάση εξερεύνησης, λόγω της εναλλαγής διαφορετικών καταστάσεων (states). Ωστόσο, μετά το επεισόδιο ~4000,

παρατηρείται σταθεροποίηση σε συγκεκριμένα επίπεδα.

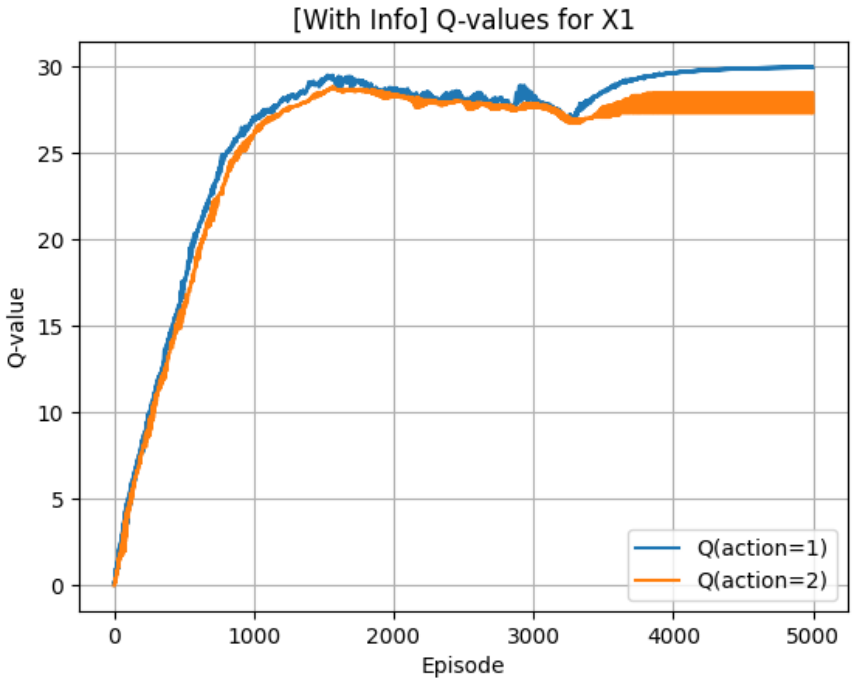

Για τον X1, οι δύο Q-τιμές παραμένουν σχετικά κοντά σε όλη τη διάρκεια της μάθησης, γεγονός που υποδηλώνει ότι ο X1 βρίσκεται σε λιγότερο στρατηγικά καθοριστική θέση στο δίκτυο. Παρότι η ενέργεια 1 τελικά υπερισχύει, η διαφορά είναι μικρότερη σε σχέση με τον X3, αντανακλώντας την τοπολογική του θέση.

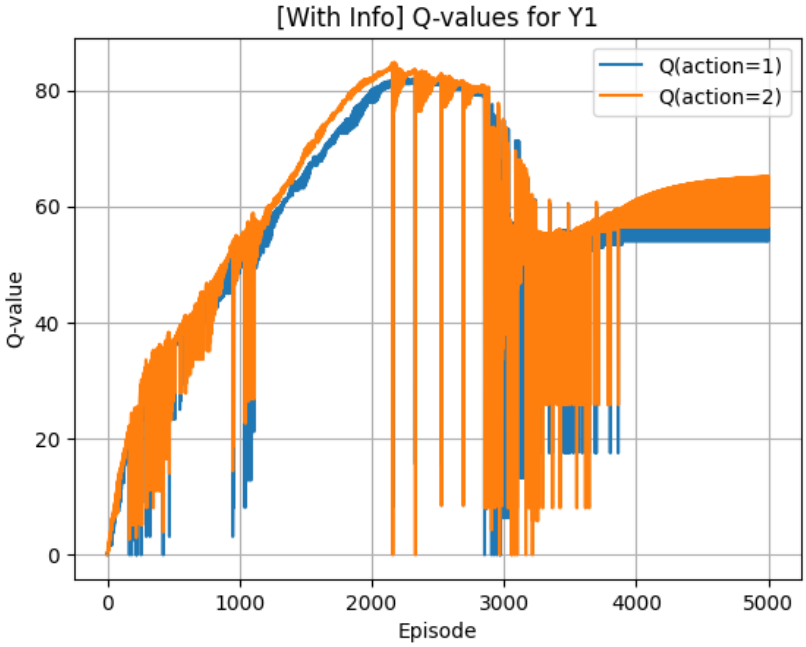

Για τον Y1, οι Q-τιμές παρουσιάζουν έντονη διακύμανση κατά τη φάση εξερεύνησης, καθώς ο πράκτορας βιώνει διαφορετικές καταστάσεις γειτονίας. Μετά τη μείωση του ε, η ενέργεια 2 εμφανίζεται ως κυρίαρχη, με υψηλότερη σταθεροποιημένη Q-τιμή. Το αποτέλεσμα είναι συνεπές με τις προτιμήσεις του τύπου Y.

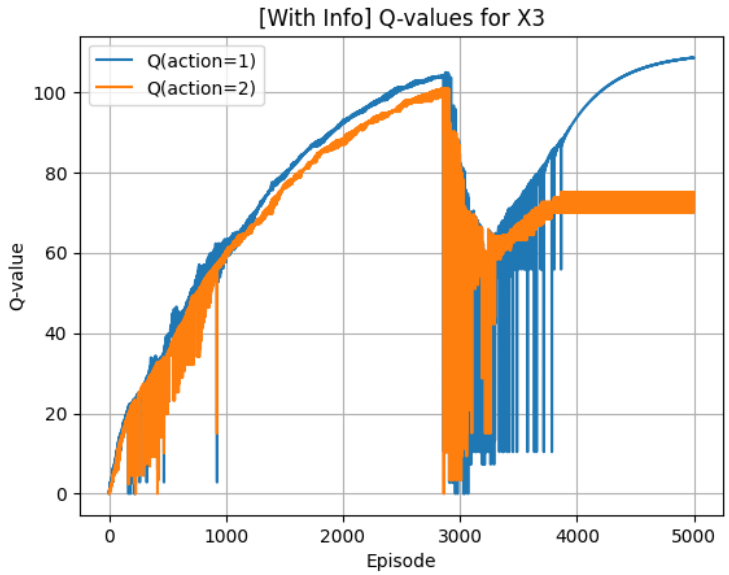

Για τον X3 , οι Q-τιμές αυξάνονται σημαντικά λόγω της προεξοφλημένης μελλοντικής ανταμοιβής (γ=0.95), προσεγγίζοντας τιμές της τάξης $\frac{r}{1-\gamma}$. Παρατηρείται απότομη πτώση γύρω στο επεισόδιο ~3000, η οποία αντιστοιχεί σε αλλαγή κυρίαρχου convention. Τελικά η ενέργεια 1 υπερισχύει, υποδηλώνοντας ότι ο X3 συντονίζεται στη δράση που ευνοεί τον τύπο X.

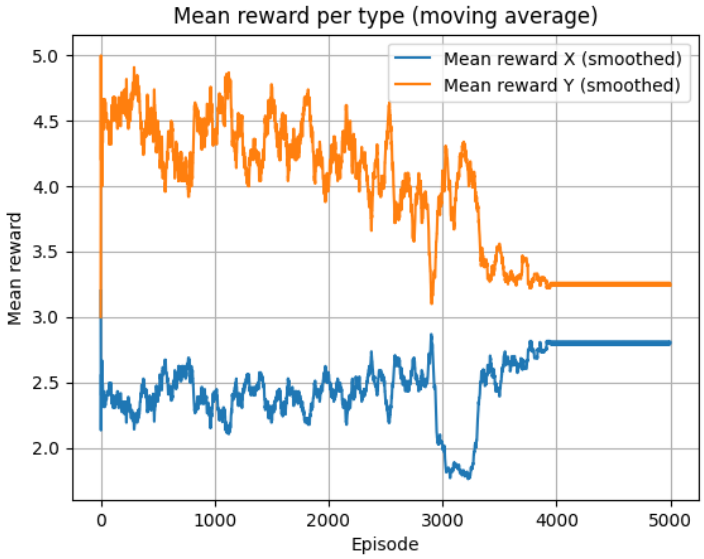

Στο διάγραμμα μέσης ανταμοιβής ανά τύπο, οι καμπύλες παρουσιάζουν έντονες διακυμάνσεις στην αρχή (μέχρι περίπου το επεισόδιο 3000). Μετά το επεισόδιο ~4000, όπου ξεκινά η εκμετάλλευση , παρατηρείται σταθεροποίηση: η μέση ανταμοιβή των X συγκλίνει περίπου στο 2.8, ενώ των Y περίπου στο 3.0.Η μικρή υπεροχή του τύπου Y ερμηνεύεται ακριβώς όπως πριν.

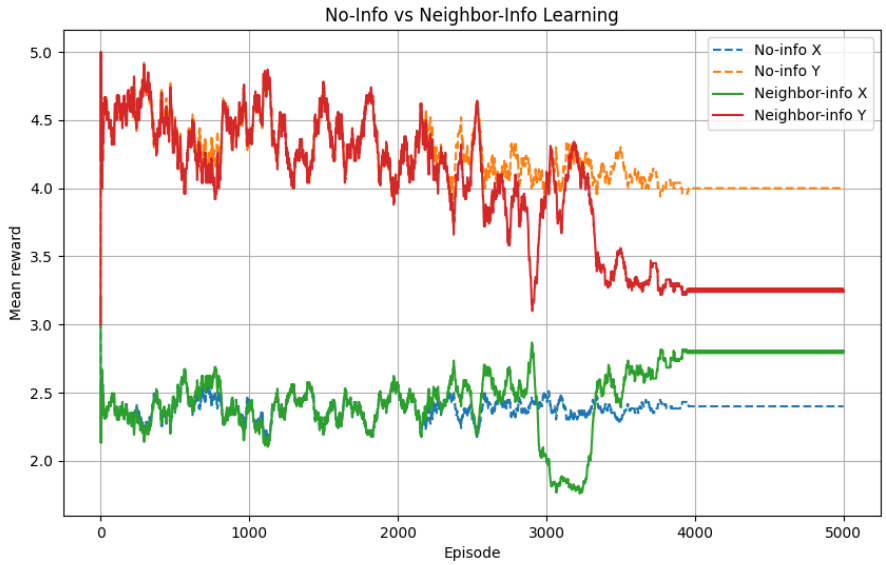

Τέλος, το παραπάνω σχήμα τοποθετεί αντιπαραθετικά τις δύο συνθήκες στις οποίες εκπαιδεύτηκαν οι πράκτορες. Παρατηρείται ότι στο No- Info οι Y τείνουν να καταλήγουν σε υψηλότερη σταθερή ανταμοιβή από τους X, ενώ στο Neighbor- Info οι καμπύλες συγκλίνουν σε πιο κοντινές τιμές, κάτι που υποδηλώνει ότι η επιπλέον πληροφορία γειτόνων βοηθά στη σταθεροποίηση ενός πιο ισορροπημένου convention.

5. Συμπεράσματα

Τα αποτελέσματα δείχνουν ότι το σύστημα συγκλίνει σε σταθερή κατάσταση συντονισμού και στις δύο συνθήκες πληροφόρησης. Ωστόσο, η ποιότητα και η ισορροπία του τελικού convention επηρεάζονται από τη διαθεσιμότητα τοπικής πληροφορίας. Στην απουσία πληροφορίας, η τελική ισορροπία καθορίζεται κυρίως από την τοπολογική επιρροή συγκεκριμένων κόμβων, οδηγώντας σε μεγαλύτερη ανισορροπία μεταξύ των τύπων X και Y. Αντίθετα, όταν οι πράκτορες λαμβάνουν υπόψη τις ενέργειες των γειτόνων τους, η σύγκλιση οδηγεί σε πιο ισορροπημένη κατανομή ανταμοιβών και μεγαλύτερη σταθερότητα της δυναμικής.

Συνεπώς, η τοπική πληροφορία δεν επηρεάζει μόνο την ταχύτητα μάθησης αλλά και τη μορφή της τελικής ισορροπίας, αναδεικνύοντας τον κρίσιμο ρόλο της δομής του γράφου στη συλλογική συμπεριφορά των πρακτόρων.